Fuentes de Conocimiento (Adquisición)

- **Estándares Semánticos W3C:**
- **DCAT (Data Catalog Vocabulary - W3C):** Proporciona conceptos estándar para catalogar conjuntos de datos y servicios de datos.
- **PROV-O (Provenance Ontology - W3C):** Modela linaje, transformaciones y agentes responsables de la generación de datos.
- **Marcos Regulatorios y Normativos:**
- *Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados (LGPDPPSO):* Define categorías de datos identificativos, sensibles y el principio de retención/bloqueo.
- *Catálogo y Lineamientos de Gobierno de TI Institucional:* Define áreas generadoras (Control Escolar, Finanzas, Biblioteca, Tutorías), custodios y periodos de retención académica/contable.

Análisis e Integración de Vocabularios Existentes

A. W3C DCAT (dcat:)

Qué se reutiliza:

- dcat:Catalog: Para representar el catálogo global de datos institucionales.
- dcat:Dataset: Como superclase de nuestros conjuntos de datos (:ConjuntoDeDatos), tales como tablas relacionales, vistas materializadas y datasets analíticos.
- dcat:theme / dcat:keyword: Para clasificación por dominios académicos/administrativos.

Qué se descarta y por qué:

- Se descartan clases como dcat:Distribution y dcat:DataService con detalles de transporte web (formatos binarios, endpoints de descarga REST o APIs de publicación abierta). En este caso el objetivo es gobernar el

almacenamiento interno, linaje y privacidad, por lo que modelar la distribución física de archivos agregaría complejidad innecesaria (violando el principio de *mínimo compromiso ontológico* de Gruber).

B. W3C PROV-O (prov:)

Qué se reutiliza:

- prov:Entity: Como superclase abstracta de cualquier activo de información (tablas, reportes, columnas).
- prov:Activity: Como superclase de las ejecuciones de extracción y transformación (:ProcesoETL).
- prov:Agent: Superclase para custodios y dependencias institucionales (:Responsable, :Departamento).
- Propiedades de linaje: prov:wasGeneratedBy (un dataset o reporte generado por un ETL), prov:used (tablas leídas por un ETL) y prov:wasAttributedTo (responsabilidad sobre un activo).

Qué se descarta y por qué:

- Se descartan los detalles de granularidad temporal de PROV-O (prov:startedAtTime, prov:endedAtTime, prov:Generation, planes complejos de delegación entre software y personas). Modelar la micro-trazabilidad de ejecuciones por lote desborda el alcance de las preguntas de competencia, que solo exigen rastrear la ruta estática y dependencia entre fuentes y tableros.

Matriz de integración y Justificación

Término Propio	Vocabulario Externo	Axioma de Mapeo / Integración	Decisión Técnica y Justificación
:ConjuntoDeDatos	DCAT (dcat:Dataset)	rdfs:subClassOf dcat:Dataset	Se alinea con el concepto de conjunto de datos del W3C para interoperabilidad externa.
:ActivoDeInformacion	PROV-O (prov:Entity)	rdfs:subClassOf prov:Entity	Permite que cualquier tabla, reporte o columna sea rastreable en un grafo de procedencia.
:ProcesoETL	PROV-O (prov:Activity)	rdfs:subClassOf prov:Activity	Modela la actividad que consume entradas (prov:used) y emite salidas (prov:wasGeneratedBy).
:Custodio	PROV-O (prov:Agent)	rdfs:subClassOf prov:Agent	Modela a la persona o rol responsable ante la ley y la institución sobre la integridad del activo.
dcat:Distribution	DCAT	*Descartado*	Añade metadatos de compresión, URLs y bytes que no impactan

			la gobernanza del catálogo.
prov:Plan / prov:SoftwareAgent	PROV-O	*Descartado*	Simplificado como un agente institucional directo para mantener la decidibilidad y claridad de consultas.

Glosario de Terminos

Término	Definición	Tipo	Fuente	Sinónimos
ActivoDeInformacion	Elemento lógico o estructurado que almacena o procesa datos institucionales.	Clase	ISO / IEC 27001	Recurso de información
FuenteDeDatos	Repositorio o base de datos de origen transaccional donde nacen los registros.	Clase	Arquitectura TI	Sistema fuente, Origen

ConjuntoDeDatos	Colección estructurada de datos organizada en registros o filas.	Clase	DCAT (dcat:Dataset)	Dataset
Tabla	Estructura bidimensional de filas y columnas pertenecient e a una base de datos.	Clase	Modelo Relacional	Entidad relacional
Columna	Campo o atributo atómico que conforma una tabla o vista.	Clase	Modelo Relacional	Campo, Atributo
ProcesoETL	Pipeline de extracción, transformaci ón y carga que traslada datos entre fuentes.	Clase	PROV-O (prov:Activity)	Pipeline, Tarea ETL
Reporte	Artefacto visual, dashboard o	Clase	BI / Analítica	Tablero analítico,

	tablero analítico para toma de decisiones.			Cuadro de mando
NivelConfidencialidad	Grado de restricción y reserva legal asignado a un activo.	Clase	LGPDPPSO	Clasificación de seguridad
Confidencial	Dato protegido por ley o secreto que requiere acceso restringido.	Instancia / Clase	LGPDPPSO	Reservado
Publico	Dato de libre acceso y difusión sin restricciones normativas.	Instancia / Clase	LGPDPPSO	Abierto
DatoPersonal	Información numérica, alfabética o fotográfica concerniente a una persona	Clase	LGPDPPSO	PII

	física identificada o identificable.			
DatoSensible	Dato personal que afecta la esfera más íntima del titular o cuya utilización indebida dé origen a discriminación.	Clase	LGPDPPSO	Dato especialmente protegido
Custodio	Agente individual o rol responsable formal de la integridad, calidad y gobierno de una fuente o tabla.	Clase	DAMA-DMBOK / PROV-O	Responsable de datos, Data Owner
Departamento	Unidad académica o administrativa generadora	Clase	Orgánica Institucional	Área, Dependencia

	o usuaria de información.			
PeriodoConservacion	Plazo reglamentario máximo o mínimo durante el cual los datos deben preservarse antes de su bloqueo o purga.	Atributo / Propiedad	Archivo General / LGPDPPSO	Retención, Vigencia documental
perteneceAFuente	Relación que asocia una tabla o vista con su base de datos o sistema de origen.	Relación	Modelo Relacional	almacenadoEn
tieneColumna	Relación que descompone una tabla en sus atributos constituyentes.	Relación	Modelo Relacional	compuestoPor

alimentaA	Relación de procedencia entre una fuente/tabla y el proceso ETL o reporte que la consume.	Relación	PROV-O (prov:used)	esInsumoDe
generaActivo	Relación de salida que indica qué tabla o reporte es producido por un proceso ETL.	Relación	PROV-O (prov:wasGeneratedBy)	produce
tieneCustodio	Relación que vincula una fuente o tabla con el agente responsable de su custodia.	Relación	PROV-O (prov:wasAttributedTo)	tieneResponsable
tieneClasificacion	Relación que asocia un activo o columna con su nivel de	Relación	Seguridad TI	clasificadoComo

	confidencialidad o privacidad.			

Árbol de clasificación taxonómica

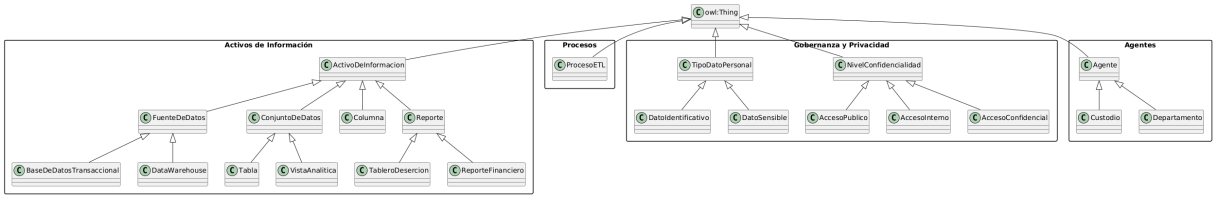
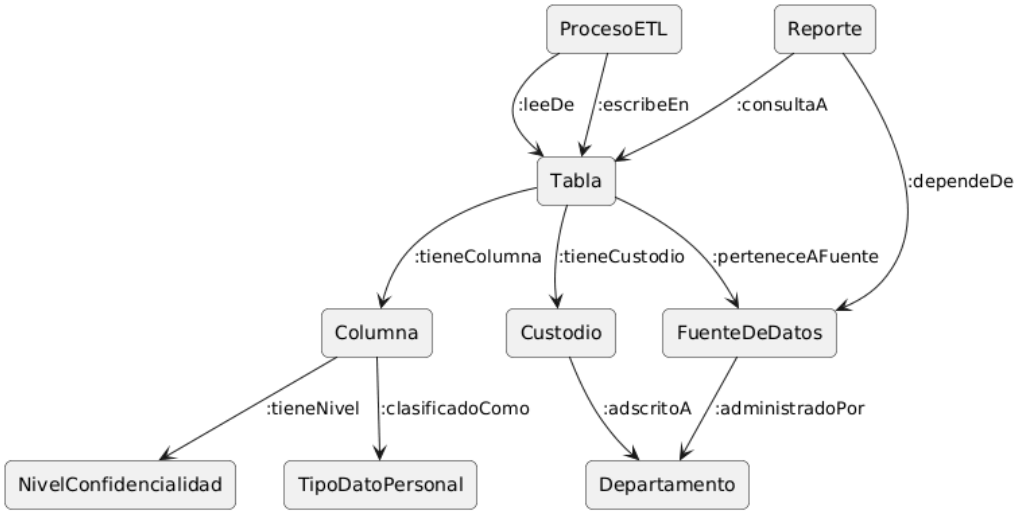


Diagrama de Relaciones Binarias



Diccionario de conceptos

Concepto	Atributos (Data Properties)	Relaciones con otros conceptos (Object Properties)	Instancias representativas
FuenteDeDatos	nombreFuente (string), motorBD (string)	administradoPor →Departamento	BD_ControlEscolar, BD_Finanzas, BD_Tutorias, BD_Biblioteca
Tabla	nombreTabla (string), mesesRetencion (integer), fechaCreacion (dateTime)	perteneceAFuente →FuenteDeDatos, tieneColumna →Columna, tieneCustodio →Custodio	tbl_Alumnos, tbl_Kardex, tbl_PagosColegiatura, tbl_SesionesTutoria
Columna	nombreColumna (string), tipoDatoSql (string)	clasificadoComo →TipoDatoPersonal, tieneNivel →NivelConfidencialidad	col_CURP, col_Promedio, col_IngresoFamiliar, col_Matricula
ProcesoETL	idPipeline (string), frecuenciaEjecucion (string)	leeDe →ConjuntoDeDatos, escribeEn →ConjuntoDeDatos	ETL_CargaDesercion, ETL_ConsolidacionFinanzas
Reporte	tituloReporte (string),	consultaA →ConjuntoDeDatos, dependeDe	Dashboard_Desercion, Tablero_Morosidad

	esConfidencial (boolean)	→ActivoDeInformacion	
Custodio	nombreCompleto (string), correoInstitucional (string)	adscritoA →Departamento	Custodio_Escolar, Custodio_Finanzas
Departamento	nombreDepartamento (string), claveArea (string)	*(Inversa de administradoPor)*	Depto_ControlEscolar, Depto_Tutorias

Justificación de la elección de OWL 2 DL

El catálogo requiere modelar taxonomías de activos, restricciones de dominio y rango en relaciones de linaje, disyunción estricta entre niveles de acceso (AccesoPublico, AccesoInterno y AccesoConfidencial), y propiedades transitivas como :dependeDe para rastrear dependencias indirectas desde los tableros analíticos hasta las fuentes de datos originales.

- **Por qué no RDFS:** RDFS carece de soporte para clases disjuntas, transitividad y restricciones de cardinalidad. Bajo RDFS no sería posible asegurar que un activo confidencial no sea marcado simultáneamente como público.
- **Por qué no OWL 2 EL / QL:** El perfil EL no soporta propiedades inversas ni disyunciones completas, mientras que QL restringe las propiedades transitivas y las restricciones existenciales en el lado derecho de las subclases.
- **Por qué no OWL 2 RL:** Aunque RL maneja reglas polinomiales sobre datos, impone limitaciones en la posición de axiomas existenciales. OWL 2 DL ofrece la expresividad exacta necesaria manteniendo la **decidibilidad** del razonamiento con motores como HermiT.

- **Elección de la sintaxis Turtle:** Es compacta, legible para humanos y permite un control de versiones limpio en Git, evitando el ruido de diferencias generado por formatos como RDF/XML.

Delimitación: qué queda fuera de la ontología (SHACL y aplicación)

Siguiendo el principio de *mínimo compromiso ontológico* de Gruber y considerando la hipótesis de *mundo abierto* (Open World Assumption, OWA) propia de OWL, se excluyen de la ontología pura dos tipos de reglas:

1. **Validación de campos obligatorios e integridad (SHACL):** En OWL, que una tabla no tenga un custodio explícito no genera una contradicción; el razonador simplemente asume que existe en alguna parte pero no ha sido registrado. La exigencia de que *«toda tabla en producción debe tener asignado obligatoriamente al menos un custodio»* se delega a formas de validación con **SHACL** bajo mundo cerrado.
2. **Cálculo de vencimiento de retención y alertas (Lógica de la aplicación / SPARQL):** El cálculo dinámico de si un conjunto de datos superó su periodo de conservación requiere comparar fechas del sistema contra enteros de meses y detonar acciones de depuración. Ni OWL ni SHACL ejecutan acciones reactivas en bases de datos; esta tarea se gestiona mediante consultas analíticas SPARQL (FILTER, fechas relativas) o en el backend del catálogo institucional.